

אלגוריתמים בראייה

ממוחשבת

046746

רטוב 1

דניאל טייטלמן – 207734088

Daniel.tei@campus.technion.ac.il

יאיר נחום – 034462796

nahum.yair@campus.technion.ac.il

1. טענו את התמונה של model_chickenbroth.jpg והצגנו אותה.



2. על מנת ליצור פירמידה גאוסית השתמשנו בפונקציה הנתונה, כאשר ביצענו את שלבי ה – PREPROCESSING הבאים לתמונה: המרה מ – RGB ל GRAY ולאחר מכן מעבר מתצוגה ב 8UINT להצגה ע"י FLOAT בין 0 ל 1. תוצאת הפירמידה הגאוסית שהתקבלה היא בעלת הממדים הבאים:

Gaussian pyramid shape: (6, 139, 98)

של רכיבי הפירמידה HSTACK והתמונה המתקבלת מוצגת היא באמצעות פריסה ע"י



3. מימשנו את פירמידת ה – DoG, ביצענו זאת באמצעות ההפרשים בין הרמות השונות של הפירמידה הגאוסית. כאשר לבסוף קיבלנו פירמידה בעלת הממדים הבאים:

DoG pyramid shape: (5, 139, 98)

של רכיבי הפירמידה HSTACK והתמונה מוצגת באמצעות פריסה ע"י



4. כעת מימשנו את EDGE SUPPRESSION בשלבים הבאים:

א. חישוב של ההסיאן H באמצעות ביצוע 3 פילטרי SOBEL בעלי המאפיינים הבאים: D_{xx} כך שפילטר SOBEL מבוצע פעמיים על ציר x ואפס פעמיים על ציר y , D_{yy} כך שפילטר SOBEL מבוצע פעמיים על ציר y ואפס פעמיים על ציר x , D_{xy} כך שפילטר SOBEL מבוצע פעם אחת

על ציר x ופעם אחת על ציר y (הפילטר סימטרי). גודל פילטר סובל הוא 3 בכל המקרים אצלנו.

ב. לאחר מכן חישבנו את ה- $Tr(H)$ ו $\det(H)$ בעבור כל נקודה בצורה הבאה:


$$Tr(H) = D_{xx} + D_{yy}$$

$$\det(H) = D_{xx} \odot D_{yy} - D_{xy}^2$$

היא מכפלה איבר איבר, וזאת מפני שאנו משתמשים בכתיב מטריצי לחישוב. \odot כאשר ג. חישוב יחס העקמומיות R איבר איבר בצורה הבאה:

$$R = \frac{Tr(H)^2}{\det(H)}$$

אם נציג תמונה ללא סף בינארי נקבל.




ד. ביצוע סף בינארי למטריצת ערכי העקמומיות R עם הגודל $\theta_r = 12$.

חישוב זה בוצע בעבור כל רמה בפירמידה הגאוסית. (חישוב זה מבוצע ב 1.5 אך מוסף כאן, כדי לקבל את התמונות והוא מבוצע כסף קשיח ולא כ"גמיש")

הם: *Principal Curvature* הממדים של מטריצת ה –

Principal curvature shape: (5, 139, 98)

EDGE SUPPRESSION התוצאה הסופית בעבור 4 רמות הפירמידה לאחר



5. בסעיף זה מצאנו את המינימום והמקסימום המקומיות בצורה הבאה.

בעבור $th_{contrast}$ על פי הערכים של *Thresholding* שמוגדר באמצעות *MASK* ראשית כל יצרנו הפרש הפירמידות הגאוסיות (בערך מוחלט) כאשר תנאי זה מתקיים יחד עם התנאי כי thr העקמומיות הראשית קטנה מ –

שמקיימות את התנאי ובדקנו בשכנות של 8 (באותה *MASK* לאחר מכן עברנו על כל הנקודות ב הרמה) ובעומק אחד מעל ומתחת בשכנות 9 האם מתקבל מינימום או מקסימום מקומי. אם כן *locsDoG* הוספו על פי הסדר של האינדקסים שהתבקשו למערך

Locs DoG shape: (237, 3)


6. כעת חיברנו את כלל החלקים השונים של האלגוריתם כעת נבחן את האלגוריתם על כמה תמונות שונות, ובמצבים שונים.

ראשית נתחיל מן התמונה הראשונית שקיבלנו.



נפעיל את האלגוריתם ראשית עם פרמטרים שונים. בכלל התמונות העיגולים מסמנים את מיקום המאפיינים, וגודלם קשור לרמה בה הם מופיעים.


$Thr = 12$ and $Th_{contrast} = 0.03$



$Thr = 12$ and $Th_{contrast} = 0.015$



$Thr = 12$ and $Th_{contrast} = 0.005$



$Thr = 1$ and $Th_{contrast} = 0.03$




$Thr = 10000$ and $Th_{contrast} = 0.03$




הוא בחירה יחסית טובה ויחסית רובסטי, לעומת זאת $r = 12$ כפי שניתן לראות הערך של היא בעלת השפעה משמעותית ולכן אנו עלולים להגיע למקרה הקיצון $Th_{contrast}$ הבחירה של כמו התמונה האמצעית או למקרה השני בו יש מעט מאפיינים כמו בתמונה השמאלית ביותר, על כן יש חשיבות לבחירת מקדם זה. בעבור תמונה נוספת שבדקנו:



$Thr = 12$ and $Th_{contrast} = 0.03$



$Thr = 12$ and $Th_{contrast} = 0.015$




$Thr = 12$ and $Th_{contrast} = 0.005$



$Thr = 1$ and $Th_{contrast} = 0.03$



$Thr = 10000$ and $Th_{contrast} = 0.03$



שוב ניתן לראות תוצאות דומות להסבר שתואר לפני כן.

כעת בדקנו בעבור תמונה טבעית שצילמנו.




ולאחר הרצת האלגוריתם.


$Th_r = 12$ and $Th_{contrast} = 0.03$



$Th_r = 12$ and $Th_{contrast} = 0.015$




$Th_r = 12$ and $Th_{contrast} = 0.005$



$Th_r = 1$ and $Th_{contrast} = 0.03$



$Th_r = 10000$ and $Th_{contrast} = 0.03$



כעת התמונה האמצעית היא הגרועה ביותר, לעומת השמאלית ביותר אשר היא הטובה ביותר. על כן יש לבדוק כי אכן פרמטרי האלגוריתמים מותאמים היטב לתמונות טבעיות או באופן מדויק יותר בעבור סוג התמונות אשר האלגוריתם אמור להתמודד איתם בעולם האמיתי.

Part B:

2. Brief Descriptor (code is at code/part_B/ the results are at data/my_data/)
 - 2.1. See implementation in my_BRIEF.py code. The main.py module uses it and creates the testPattern.mat file at every run of main.py
From the article methods we've implemented the uniform distribution randomization on patch locations.
 - 2.2. See in my_BRIEF.py. We've implemented comupteBrief function by first filtering out any point that doesn't have the required support (9x9) within the image pixels' boundaries.
Then, we've built the 'm' locations' descriptors:
We've converted the 9x9 support per location to a flat vector of 81x1. Then, we've taken the 2 series of pairs, X_n and Y_n , and get the vector according the Rho function defined (to get the binary vector as a descriptor per feature location). It could have

been bits (to save memory and get better performance on distance calculations) but we're not required to save in bits.


2.3. Here, we simply load the testPattern.mat in which we save the parameters for briefLite function (not only compareX and compare fields in hash).

We then get the DoG features and the Gaussian pyramid and use them together with other parameters to calculate the filtered (inner pixels) features' locations and their descriptors.

2.4. Descriptors' matching


We've implemented the testMatch.py script (also run from part B main.py) and plotted the results:

2.4.1. Chickenbroth image 01 vs image 04:




In the above example we can see that the brief is robust and invariant against illumination changes. This is so, since we calculate the R value in DoG filtering as a ratio between trace^2 and det of the gradient's covariance matrix. Thus, as we saw in lecture, it will be invariant to scale and illumination (better in this sense from Harris Detector).

2.4.2. incline_L vs incline_R:



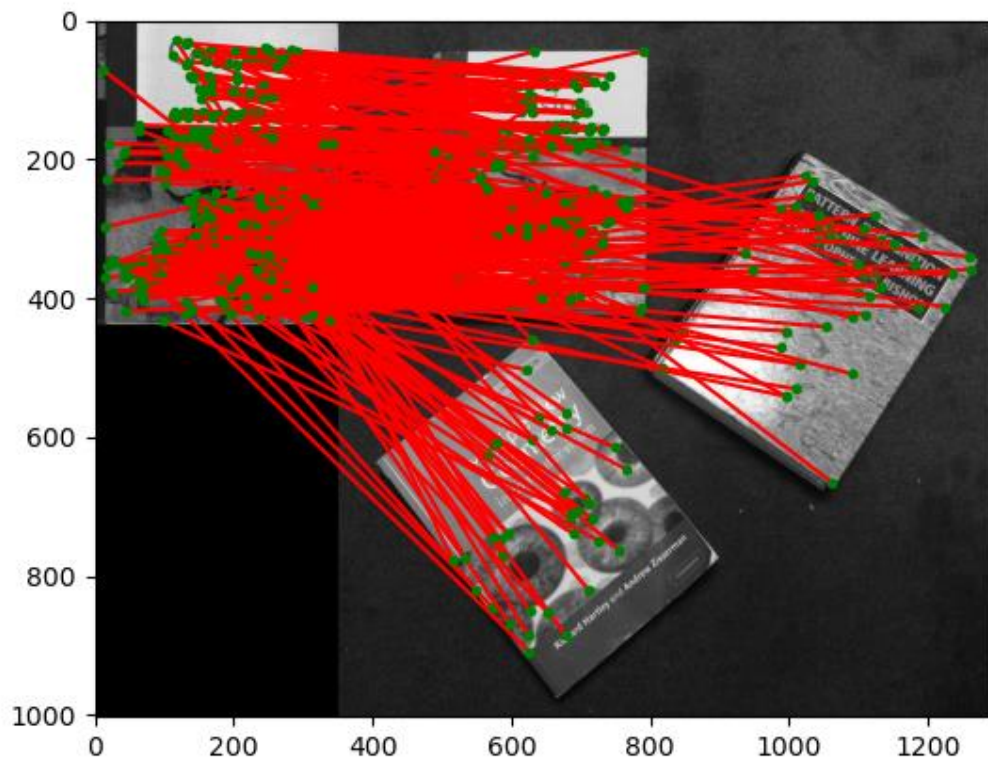
We can see that BRIEF works well also when there is a different perspective on the scene. It matches the same building.

2.4.3. pf_scan_scaled vs pf_desk:




under perspective transformation, it seems that the feature points are preserved and match.

2.4.4. pf_scan_scaled vs pf_floor:




Since the CV book image is not rotated on the floor, we can see that the BRIEF operates very good. It also finds some false matches against other books though.

2.4.5. pf_scan_scaled vs pf_floor_rot:



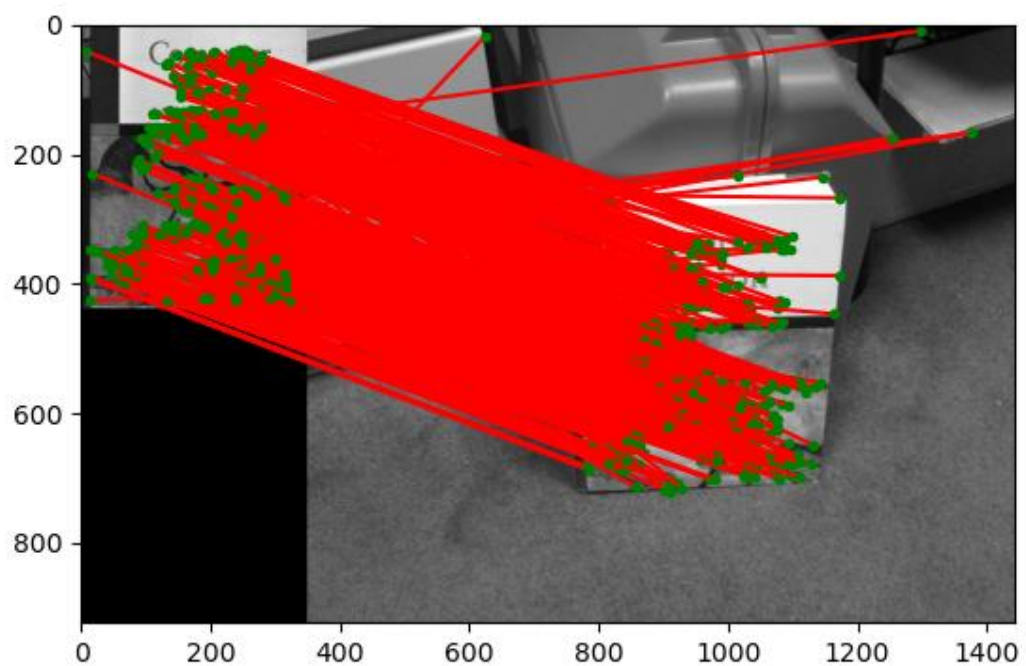
When rotation is applied, we see the performance degrade and BRIEF can't match the correct book over the others. It finds matches similarly against all books.

2.4.6. pf_scan_scaled vs pf_pile:




Again, poor performance when rotating. Now the shape of the book against the background is also not clear and BRIEF doesn't match OK.

2.4.7. pf_scan_scaled vs pf_stand:



The standing book is not rotated against the original. We have a different perspective point, but brief handles it very well as we saw in the incline_* images.

When we compare an image to itself we found a perfect match between the features:

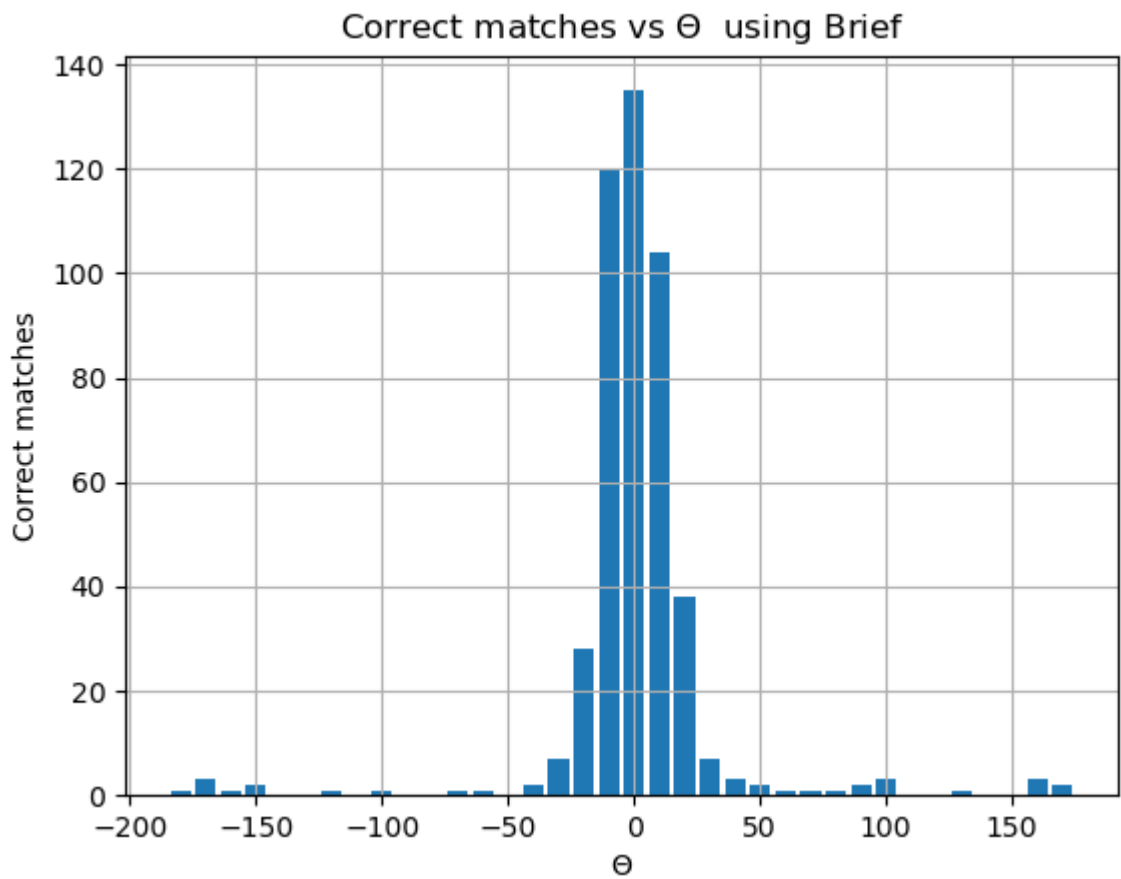


2.5.

2.5.1. As we saw in the comparison of chickenbroth images 01 and 04 the BRIEF performed well even under changes of illumination. This is so, since we calculate the R value in DoG filtering as a ratio between trace^2 and \det of the gradient's covariance matrix. Thus, as we saw in lecture, it will be invariant to scale and illumination (better in this sense from Harris Detector). Also, multiplying each pixel in the image (and also adding a bias to the pixel BTW) won't change the relation between $I(x) < I(y)$. it will preserve the same sign as we wish under illumination changes.


2.5.2. We can relate to the scale in which the feature was detected and get a patchWidth that is scaled to that scale (not only 9x9 for all scales). This is what's done in SIFT and other similar approaches.

2.5.3. Took the model_chickenbroth.jpg test image and matched it to itself while rotating the second image in increments of 10 degrees. Got the following bar plot:



It shows that we have a poor matching when the rotation is above ± 10 degrees. We can explain it by not preserving the orientation as in SIFT (in SIFT we also rotate in the needed scale to horizontal/vertical direction all the patches).

2.6. In ORB we've run the same rotation test and got the following results:



It shows that the ORB keeps matching correctly even with any rotation angle.

We can explain it by ORB borrowing from SIFT the orientation saving.

The article about ORB mentions the "Orientation by Intensity Centroid". Which is a method to keep the feature orientation.